



SVM – Support Vector Machine

Prof. Dr. Wilson Tarantin Junior

Amilcar Ferraz Farina 188.708.208-58

MBAUSP ESALA

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98


Support Vector Machine (SVM)

- Quando aplicar o modelo?

- Aplicaremos em análises supervisionadas: $Y = f(X) \rightarrow$ Inferência para novas observações
 - Comumente utilizado para tarefas de classificação: variável dependente categórica
 - Também pode ser utilizado para tarefas de regressão: variável dependente métrica
- O SVM pode implementar classificações e regressões **lineares** ou **não lineares**
 - Destaca-se por ser um modelo flexível para lidar com dados de diversas características
- Lida bem com bancos de dados de pequeno e médio porte

SVM – Classificação Linear

- O objetivo é encontrar a fronteira de decisão que melhor separe as classes de Y



- Na ilustração, há duas classes em Y indicadas por pontos azuis e laranjas
- Há separabilidade linear entre classes
- A linha em vermelho é a **fronteira de decisão** (hiperplano para muitas X)
 - As observações sobre as linhas pontilhadas são **vetores de suporte** (as mais próximas entre os grupos)
 - A fronteira de decisão está o mais distante possível dos vetores. Linhas pontilhadas mostram as **margens**

SVM – Classificação Linear

- Aspectos relevantes do modelo


- Na ilustração, os dados eram linearmente separáveis com base nas variáveis X e a separação foi perfeita (não houve a violação das margens). Frequentemente, isso não ocorre nos dados!
- Problema de otimização do SVM: maximiza a margem entre as classes, isto é, a distância entre a fronteira de decisão e os vetores de suporte, mas incorpora ao problema um termo que penaliza as observações incorretamente classificadas (aquelas dentro da margem ou do lado errado da fronteira de decisão)
- Hiperparâmetro do modelo:
 - **C**: penalização atribuída às observações incorretamente classificadas. Menores valores de **C** tendem a gerar margens maiores, pois a penalização imposta aos erros de classificação é menor!

SVM – Classificação Não Linear

- **Classificação Não Linear**

- Quando não há separabilidade linear no espaço original das variáveis explicativas (X)
- O SVM pode obter uma fronteira de decisão não linear
 - Solução: os dados originais (X) são transformados para um novo espaço no qual as observações são comparadas; nova dimensão dos dados onde pode ocorrer a separabilidade linear
 - Na prática, o SVM aplica uma função (“kernel”) que mapeia os dados e obtém as similaridades entre os pares de observações no espaço transformado; é utilizado como base no problema de otimização que busca maximizar a margem e limitar violações para obter um hiperplano que melhor separa as classes de Y

SVM – Classificação Não Linear




Fonte: <https://medium.com/>

- Truque do kernel: não é necessário obter as coordenadas das observações nesse espaço transformado; o kernel calcula a similaridade das observações no novo espaço
- **Kernel não lineares recorrentemente utilizados: Polinomial e RBF (*Radial Basis Function*)**

SVM – Classificação Não Linear


- Ilustração de uma solução polinomial



- Kernel Polinomial
- $K(a, b) = (\gamma a^T b + r)^d$
 - a e b são duas observações
- Substituindo os valores para a e b no kernel, obtém-se a relação de similaridade entre as observações proveniente do espaço transformado (como se tivesse adicionado características polinomiais das variáveis X)
- No espaço transformado a separação é pelo hiperplano, porém ao retornar para o espaço original (X) ela se mostra não linear!

SVM – Classificação Não Linear

- Ilustração de uma solução RBF



- **Kernel *Radial Basis Function* (RBF)**
- $K(a, b) = \exp(-\gamma \|a - b\|^2)$
 - **a e b são duas observações**
- Baseia-se na distância Euclidiana entre as observações: $\|a - b\|^2$
- Portanto, gera uma “distância” entre observações. Por meio dela, calcula-se o quanto as observações se assemelham. Varia de 0 (diferente) a 1 (semelhante)

SVM – Classificação Não Linear

- Parametrização do kernel não linear


- Hiperparâmetros no kernel polinomial:

- **degree**: grau do polinômio (d)
- **coef0**: influência dos polinômios de alto grau vs. baixo grau (r)
- **gamma**: intervalo de influência das observações sobre a fronteira de decisão (γ)
- **C**: penalização atribuída às observações incorretamente classificadas

- Hiperparâmetros no kernel RBF:

- **gamma**: intervalo de influência das observações sobre a fronteira de decisão (γ)
- **C**: penalização atribuída às observações incorretamente classificadas

SVM – Classificação Não Linear




Fonte: https://scikit-learn.org/stable/auto_examples/svm/plot_rbf_parameters.html

- Exemplo de impacto dos hiperparâmetros
- Kernel RBF (gamma e C)
- Para valores baixos de gamma e C, a fronteira de decisão fica mais simples e próxima da linear
- Conforme aumenta-se o C, a fronteira vai se ajustando para possibilitar menores erros de classificação e vai se tornando mais complexa
- Conforme aumenta-se o gamma, o intervalo de influência das observações fica mais justo ao redor delas (mais localizado). Isso gera fronteiras de decisões mais complexas
- Há o impacto conjunto dos hiperparâmetros!

SVM – Regressão (SVR)

- No caso da variável dependente métrica inverte-se o objetivo do modelo



- No SVR, as observações que estão dentro da margem não influenciam na solução (não são vetores de suporte). A margem pode ser interpretada como a margem de tolerância, isto é, onde os erros não são penalizados
- O hiperparâmetro específico do SVR é o **épsilon (ϵ)** e controla a largura da margem. Quanto maior o ϵ , maior é a margem
- As observações fora da margem são os vetores de suporte e impactam o modelo
- A solução pode ser linear, polinomial e RBF (com os hiperparâmetros anteriores)

SVM – Considerações

- Aspectos da implementação

- É importante que as variáveis métricas explicativas estejam padronizadas, uma vez que a identificação da fronteira de decisão é sensível à escala e amplitude das variáveis
- Separação da amostra entre treino e teste: como serão ajustados os hiperparâmetros do modelo, a separação se faz necessária
 - É viável realizar o *Grid Search* para a escolha da melhor combinação de hiperparâmetros
 - É indicado implementar a *Cross Validation* em conjunto com o *Grid Search*
- Após a escolha dos hiperparâmetros, é fundamental avaliar se ocorre ou não *overfitting*
 - Avaliar o ajuste do modelo no banco de dados de testes!

Material Complementar

Métricas de Avaliação dos Modelos

Critérios de avaliação dos modelos: classificação

- **Como identificar a qualidade das estimativas?**
- **Acurácia:** percentual de classificações corretas em relação ao total de observações analisadas, isto é, trata-se da eficiência geral do modelo
- **Sensibilidade:** percentual de classificações corretas considerando apenas as observações que são evento. Esta medida também é chamada de Recall
- **Especificidade:** percentual de classificações corretas considerado apenas as observações que não são evento

Critérios de avaliação dos modelos: classificação

- Matriz de confusão

		Sensibilidade ↓	Especificidade ↓
		Observado (Real)	
Predito (Modelo)	Sim	VP	FP
	Não	FN	VN

$$Acuracia = \frac{VP + VN}{(VP + FN + VN + FP)}$$

$$Sensibilidade = \frac{VP}{(VP + FN)}$$

$$Especificidade = \frac{VN}{(VN + FP)}$$

$$Precision = \frac{VP}{(VP + FP)}$$

$$F1\ Score = 2x \frac{Precision \times Recall}{Precision + Recall}$$

Critérios de avaliação dos modelos: regressão

- Como identificar a qualidade das estimativas?
- Calcula-se um **erro de previsão** fundamentado na diferença entre os valores observados e previstos para as observações. Quanto menor o erro, melhor é o ajuste do modelo estimado

- **Erro Quadrático Médio:** $MSE = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n}$

- **Erro Absoluto Médio:** $MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$

- **Coeficiente R²:** $R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$ Obs.: quanto mais próximo de 1 estiver o R², melhor!

Referências

- Géron, A. (2021). Mãos à obra aprendizado de máquina com Scikit-Learn, Keras & TensorFlow: conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Alta Books.

Amilcar Ferraz Farina 188.708.208-58

MBAUSP ESALA

Obrigado!

Wilson Tarantin Junior | [linkedin.com/in/wilson-tarantin-junior-359476190](https://www.linkedin.com/in/wilson-tarantin-junior-359476190)