

MBAUSP
ESALQ

TEXT MINING, SENTIMENT ANALYSIS E NLP

Professor Guilherme Lima

MBAUSP ESALA

A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização.

Lei nº 9610/98

Minhas redes

guilhermelimadev

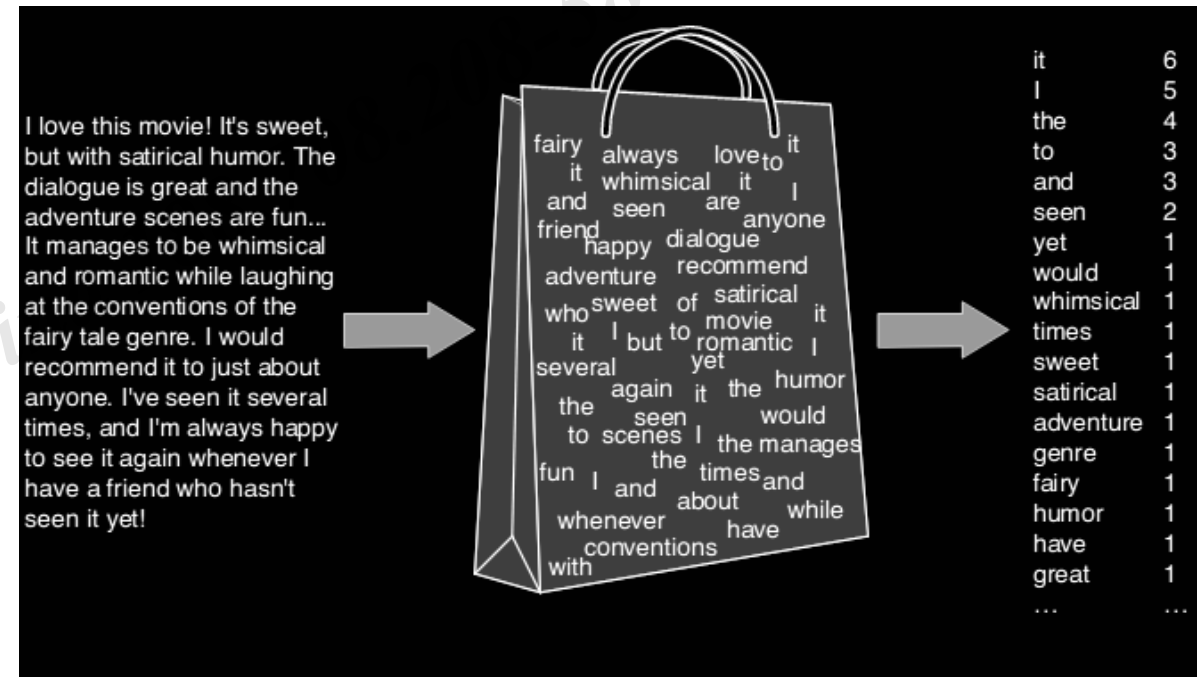


guilherme-lima-developer



Amílcar Ferraz Farina 188.708.208-58

Bag of Words?



Bag of Words

É uma forma de transformar textos em números

```
['gostei do produto', 'produto ruim', 'não gostei do produto']
```

	do	gostei	não	produto	ruim
0	1	1	0	1	0
1	0	0	0	1	1
2	1	1	1	1	0


Bag of Words

- Cada linha representa uma frase.
- Cada coluna representa uma palavra que apareceu em pelo menos uma frase.
- O valor 1 indica que a palavra está presente na frase.
- O valor 0 indica que a palavra está ausente.

```
['gostei do produto', 'produto ruim', 'não gostei do produto']
```

	do	gostei	não	produto	ruim
0	1	1	0	1	0
1	0	0	0	1	1
2	1	1	1	1	0

THE AMAZING Thomas Bayes





Thomas Bayes

1701 – 1761


arina 188.708.208-58



An Essay towards solving a Problem in the
Doctrine of Chances



Thomas
Bayes
1701-1761



Bayes **nunca publicou o teorema** em vida. Quem fez isso foi o amigo dele, Richard Price, dois anos após sua morte.

Naive Bayes

É um algoritmo de aprendizado de máquina que usa o Teorema de Bayes para calcular a probabilidade de um evento ocorrer com base em eventos anteriores. Ele é chamado de "Naive" (ingênuo) porque assume que todos os recursos são independentes uns dos outros, o que nem sempre é verdade.


Dada a frase

“Não gostei do
produto, não
recomendo”



Como?

Ele faz isso usando
probabilidades com base
em exemplos anteriores



A PROBABILIDADE DE "B" SER VERDADEIRO DADO QUE "A" É VERDADEIRO

A PROBABILIDADE DE "A" SER VERDADEIRO TRUE

$$P(A|B) = \frac{P(B|A) P(A)}{P(B)}$$

A PROBABILIDADE DE "A" SER VERDADEIRO DADO QUE "B" É VERDADEIRO

A PROBABILIDADE DE "B" SER VERDADEIRO

•
•
•

Qual a chance de algo ser verdade, dado que novas evidências apareceram?

Simulando como o Naive Bayes

Ele calcula as chances de uma frase ser de cada classe (positivo ou negativo), multiplicando:

- A chance da classe aparecer ($P(\text{positivo})$ ou $P(\text{negativo})$),
- Pela chance de cada palavra aparecer naquela classe (como $P(\text{"ótimo"} \mid \text{positivo})$).
- O nome “Naive” vem da *suposição ingênua* de que todas as palavras são independentes entre si.



N

O que é um N-gram?

O que é um N-gram?

Um N-gram é uma sequência de n palavras consecutivas em um texto.

“O produto chegou antes do prazo.”

Unigrama ($n=1$): ["O", "produto", "chegou", "antes", "do", "prazo"]

Bigramas ($n=2$): ["O produto", "produto chegou", "chegou antes", ...]

Trigramas ($n=3$): ["O produto chegou", "produto chegou antes", ...]

Como o N-gram funciona?

O N-gram "desliza" uma janela de tamanho n sobre o texto e coleta as palavras consecutivas.

Frase: "Não recebi o produto."

Bigramas:

"não recebi"


"recebi o"

"o produto"



Quanto maior o n , mais contexto você captura.

- ✓ Classificação de sentimentos
- ✓ Detecção de spam
- ✓ Tradução automática
- ✓ Correção ortográfica
- ✓ Análise de padrões em reclamações



A probabilidade de uma palavra depende das palavras anteriores

Modelo de Markov de ordem

$$N:P(w_n \mid w_{n-1}, \dots, w_{n-(n-1)})$$

Já o bigrama:

$$(n=2):P(w_2 \mid w_1) \approx \frac{\text{Contagem}(w_1, w_2)}{\text{Contagem}(w_1)}$$

Quanto mais frequente uma sequência, maior sua probabilidade.

Moral da história:

Quanto maior o N, mais contexto você capta — mas também precisa de mais dados para manter bons resultados.

Unigrama vê quais palavras aparecem.

Bigrama vê como elas aparecem juntas — ou seja, o contexto.

Trigrama é ideal para identificar expressões comuns e significativas,

MBAUSP ESALQ

Obrigado!

Professor Guilherme Lima | [linkedin.com/in/guilherme-lima-developer](https://www.linkedin.com/in/guilherme-lima-developer)